

Processo seletivo - Análise de dados de um processo seletivo de bolsas

Lucas Henrique Girasol

Abril, 2026

1 Introdução

Este relatório analisa uma base de dados disponibilizada através deste link, com 3000 alunos, contendo informações sobre sexo, idade, orientação sexual, raça/cor, se possui deficiência ou não, se foi selecionado ou não e o seu número de identificação.

O objetivo deste relatório é comparar o perfil dos alunos selecionados e não selecionados neste processo seletivo, utilizando técnicas aprendidas nas disciplinas de visualização e exploração de dados, metodologia científica e introdução a ciência da computação.

Na base de dados, a variável de desfecho é "Selecionado", que assume os valores "sim" e "não".

2 Metodologia

Para a criação dos gráficos, foi utilizado Python com as bibliotecas Pandas, Matplotlib e Seaborn, com apoio da ferramenta de IA generativa Gemini 3.1 Pro na elaboração do código.

Foram observadas no banco de dados respostas como "prefiro não informar" e "não informada". Optou-se por não remover esses registros, analisando-os como grupos qualitativos independentes.

Na subseção de nome "Perfil dos Candidatos Selecionados" foram usados gráficos de barras empilhados para que seja possível comparar o perfil dos candidatos selecionados e não selecionados.

3 Análise Exploratória e Visualização de Dados

Nesta seção serão colocados gráficos, obtidos através do banco de dados citado mais acima.

3.1 Caracterização Geral do Banco de Dados

Ao analisar a amostra completa (posteriormente, serão analisados apenas os aprovados), obtêm-se os seguintes resultados:




Tabela 1 - Distribuição geral por sexo

Sexo	Quantidade	Porcentagem (%)
F	1574	52.5
M	1426	47.5




Tabela 2 - Distribuição geral por orientação sexual

Orientação Sexual	Quantidade	Porcentagem (%)
Heterossexual	1851	61.7
Bissexual	620	20.7
Homossexual	274	9.1
Prefiro não responder	144	4.8
Pansexual	95	3.2
Outro	16	0.5




Tabela 3 - Distribuição geral por raça-cor

Raça-cor	Quantidade	Porcentagem (%)
Branca	1596	53.2
Parda	880	29.3
Preta	333	11.1
Não informada	125	4.2
Amarela	63	2.1
Indígena	3	0.1




Tabela 4 - Distribuição geral por deficiência

Deficiência	Quantidade	Porcentagem (%)
Não possui	2886	96.2
Outro	42	1.4
Deficiência Visual	25	0.8
TEA – Transtorno Espectro do Autismo	21	0.7
Deficiência Mental/Intelectual	11	0.4
Deficiência Física	11	0.4
Deficiência Auditiva	4	0.1




Tabela 5 - Estatísticas descritivas de idade (geral)

Variável	Quantidade	Média	Desvio Padrão	Mínima	Mediana	Máxima
Idade	3000.0	22.4	4.5	17.0	21.0	62.0

3.2 Perfil dos Candidatos Selecionados

Variáveis qualitativas

Quanto à proporção de selecionados por sexo, apresenta-se:




Tabela resumo - Sexo				
Sexo	Não	Sim	Não (%)	Sim (%)
F	559	1015	35.5	64.5
M	514	912	36.0	64.0

É evidente que a taxa de seleção ficou praticamente igual entre os sexos (F: 64,5% e M: 64,0%). Então, pelos dados descritivos, é possível dizer que o sexo não se mostrou um fator relevante para a seleção.

Quanto à proporção de selecionados por orientação sexual, apresenta-se:




Tabela resumo - Orientação sexual

Orientação Sexual	Não	Sim	Não (%)	Sim (%)
Bissexual	220	400	35.5	64.5
Heterossexual	674	1177	36.4	63.6
Homossexual	90	184	32.8	67.2
Outro	4	12	25.0	75.0
Pansexual	33	62	34.7	65.3
Prefiro não responder	52	92	36.1	63.9

Na variável orientação sexual acontece algo parecido: as taxas de seleção ficam próximas na maior parte dos grupos (em geral entre 63% e 67%). Nas categorias muito pequenas, como "Outro", qualquer variação deve ser lida com cuidado por causa do tamanho amostral baixo.

Quanto à proporção de selecionados por raça-cor, apresenta-se:




Tabela resumo - Raça-cor

Raça-cor	Não	Sim	Não (%)	Sim (%)
Amarela	30	33	47.6	52.4
Branca	687	909	43.0	57.0
Indígena	2	1	66.7	33.3
Não informada	40	85	32.0	68.0
Parda	244	636	27.7	72.3
Preta	70	263	21.0	79.0

Em raça-cor, as diferenças de taxa aparecem de forma mais visível (por exemplo, Preta: 79,0%, Parda: 72,3%, Branca: 57,0%). Isso sugere maior heterogeneidade nessa variável, mas a confirmação dessa diferença depende de testes inferenciais.

Quanto à proporção de selecionados por deficiência, apresenta-se:




Tabela resumo - Deficiência

Deficiência	Não	Sim	Não (%)	Sim (%)
Deficiência Auditiva	1	3	25.0	75.0
Deficiência Física	3	8	27.3	72.7
Deficiência Mental/Intelectual	4	7	36.4	63.6
Deficiência Visual	11	14	44.0	56.0
Não possuo	1033	1853	35.8	64.2
Outro	11	31	26.2	73.8
TEA – Transtorno Espectro do Autismo	10	11	47.6	52.4

Na variável deficiência, o grupo "Não possuo" concentra a maior parte dos candidatos, mas as taxas entre categorias variam (aprox. 52% a 75%). Como alguns grupos têm poucos casos, essas diferenças podem oscilar bastante e precisam ser interpretadas com cautela.

Variáveis quantitativas

Quanto à variável idade, apresentam-se um boxplot da distribuição de idades e um gráfico da curva de densidade:




Tabela 1 - Estatísticas descritivas de idade (Quantidade, Média e Desvio Padrão)

Selecionado	Quantidade	Média	Desvio Padrão
Não	1073	22.4	4.9
Sim	1927	22.3	4.3

Tabela 2 - Estatísticas descritivas de idade (Idade Mínima, Mediana e Máxima)

Selecionado	Idade Mínima	Mediana (50%)	Idade Máxima
Não	17.0	21.0	62.0
Sim	17.0	21.0	61.0

Pelo que aparece na análise descritiva, a idade não mostra diferença forte entre selecionados e não selecionados.

4 Conclusões e Discussões

O objetivo desta análise foi comparar o perfil de alunos selecionados e não selecionados nesse processo seletivo. Pela análise exploratória e descritiva, sexo e orientação sexual mostraram taxas de seleção bem próximas entre os grupos.

Já em raça-cor e deficiência, apareceram diferenças mais visíveis entre categorias. Mesmo assim, como alguns grupos têm poucos registros, essas variações precisam ser lidas com cautela.

Na idade, os valores de média e mediana entre selecionados e não selecionados ficaram bem parecidos, sem sinal forte de diferença no recorte descritivo.

Em resumo, pelos resultados descritivos, não há diferença forte no perfil por sexo, orientação sexual e idade; já em raça-cor e deficiência há diferenças aparentes que exigem confirmação por testes inferenciais.

Tendo em mente as ressalvas acima, a análise dos dados demonstra que não há evidência descritiva suficiente para inferir viés demográfico. Como não há diferença significativa na proporção de candidatos aprovados entre os diferentes recortes, concluímos que essas variáveis não são fatores determinantes para a aprovação.

5 Considerações Finais e Análises Futuras

Como continuidade deste trabalho, recomenda-se aplicar testes estatísticos formais para comparar proporções entre grupos e comparar as distribuições de idade entre selecionados e não selecionados.

Caso houvesse acesso a outras informações, análises adicionais poderiam incluir variáveis como renda familiar, tipo de escola de origem, região de residência, desempenho acadêmico prévio e nota/classificação no processo seletivo. Essas variáveis permitiriam entender melhor os fatores associados à seleção.

Por fim, para aumentar a robustez da análise, é importante verificar a qualidade dos dados (valores ausentes, categorias raras e possíveis inconsistências de preenchimento) e, quando necessário, realizar análises de sensibilidade para avaliar a estabilidade dos resultados.